

Motor de Ignición Financiera — Documentación Técnica del Modelo Predictivo

Motor de Ignición Financiera — Documentación Técnica del Modelo Predictivo

1. El problema que este modelo resuelve
2. Conceptos fundamentales (en orden de dependencia)
3. Por qué esto es mejor que suavizado exponencial (y qué perdemos al usarlo)
4. El pipeline completo (las 3 capas, de datos crudos a predicción)
5. Actualización día a día (el corazón de “por qué esto es un gemelo digital y no un reporte estático”)
6. Ejemplo numérico completo (con datos reales de la simulación)
7. Pseudocódigo de referencia (arquitectura completa)
8. Limitaciones que el equipo debe poder explicar si el jurado pregunta
9. Glosario rápido
10. Resumen ejecutivo en una frase

Motor de Ignición Financiera — Documentación Técnica del Modelo Predictivo

Para: Equipo de desarrollo (4 personas) **Propósito:** Entender la teoría matemática detrás del motor predictivo, cómo se recalibra día a día, y cómo se conecta con los datos de Nessie.

1. El problema que este modelo resuelve

No estamos prediciendo “cuánto dinero habrá mañana” (eso sería un pronóstico de nivel). Estamos prediciendo **algo más específico y más difícil**: en qué momento futuro, y con qué probabilidad, el saldo de la empresa cruzará por primera vez el cero (o un umbral de riesgo), dado que el gasto diario se comporta de forma parcialmente aleatoria.

Esto se llama en matemáticas **problema de tiempo de primer paso (first-passage time)**, y es la misma familia de problemas que usan las aseguradoras para calcular reservas de capital, o los bancos para modelar probabilidad de impago. No es un problema de “dibujar una línea de tendencia y extenderla”.

Por qué importa la distinción: una línea de tendencia (regresión lineal, suavizado exponencial) te da un punto. Nuestro modelo da una **distribución de probabilidad completa** sobre el día del cruce, de la cual se derivan el punto más probable Y el intervalo de confianza. Eso es lo que hace creíble el “Factor WOW” del demo: no decimos “va a quebrar el día 18”, decimos “hay 90% de probabilidad de que ocurra entre el día 13 y el día 26”.

2. Conceptos fundamentales (en orden de dependencia)

2.1 Variable aleatoria

Un número cuyo valor exacto no se puede predecir, pero cuyo comportamiento se puede describir con

una distribución de probabilidad. El gasto de mañana es una variable aleatoria: no sabemos el número exacto, pero sabemos que tiende a rondar cierto promedio con cierta dispersión.

2.2 Proceso estocástico

Una variable aleatoria que evoluciona en el tiempo. El saldo de caja día a día **no es una línea fija**, es una trayectoria que se revela paso a paso, y que en principio podría haber tomado infinitas rutas distintas desde el mismo punto de partida.

2.3 Movimiento Browniano (Proceso de Wiener) — $W(t)$

Es el modelo matemático estándar de “ruido acumulado en el tiempo”. Tiene tres propiedades que debemos asumir como ciertas para que el modelo funcione:

1. **$W(0) = 0$** — empieza en cero por definición
2. **Incrementos independientes** — lo que pasa hoy no depende matemáticamente de lo que pasó ayer (cada día es un nuevo “sorteo”)
3. **Incrementos con distribución normal** — el cambio entre dos instantes de tiempo sigue una campana de Gauss, con varianza proporcional al tiempo transcurrido

Supuesto que estamos haciendo (y hay que ser honestos con el equipo sobre esto): en la realidad, los gastos de una PyME no son perfectamente aleatorios e independientes — hay patrones (pagos de licencias mensuales, por ejemplo). El browniano es una **aproximación útil**, no una descripción perfecta. Funciona bien cuando hay muchas transacciones pequeñas mezcladas con algo de ruido; funciona peor si hay uno o dos gastos gigantes y esporádicos (para eso existe la alternativa de Poisson compuesto, ver sección 8).

2.4 Drift (deriva) — μ

Es la tendencia promedio de la trayectoria. Sin drift, el browniano solo tiene ruido sin dirección (sube y baja alrededor de un mismo nivel). Con drift, se le agrega una inclinación constante.

Analogía del río: el drift es la corriente que te arrastra en una dirección constante; el ruido browniano son las olas que te empujan aleatoriamente para los lados mientras la corriente te lleva.

En nuestro caso: **μ = (ingresos promedio por día) – (gastos críticos ponderados promedio por día)**. Si μ es negativo, la empresa está en trayectoria de quema neta.

2.5 Volatilidad — σ

Mide qué tan erráticas son las fluctuaciones alrededor del drift. Dos empresas con el mismo μ (mismo ritmo promedio de quema) pueden tener destinos muy distintos si una tiene σ bajo (gasto predecible) y otra σ alto (gastos explosivos e impredecibles).

Por qué esto es crítico y no cosmético: una empresa con σ alto puede quebrar mucho antes de lo que sugiere el promedio, por pura mala suerte en la secuencia de gastos. Ignorar σ y solo mirar μ es el error más común al hacer este tipo de modelos — subestima el riesgo real.

2.6 El modelo completo: Browniano con deriva

$$B(t) = B0 + \mu \cdot t + \sigma \cdot W(t)$$

Donde:

- **$B(t)$** : saldo de la cuenta en el tiempo t
- **$B0$** : saldo inicial (el anticipo capturado)
- **$\mu \cdot t$** : la parte predecible (tendencia)
- **$\sigma \cdot W(t)$** : la parte aleatoria (ruido acumulado)

2.7 Tiempo de primer paso (First-Passage Time) — τ

La pregunta que realmente nos interesa:

$$\tau = \min\{ t : B(t) = 0 \}$$

Es decir: el primer instante t en el que la trayectoria aleatoria toca cero. **No es lo mismo que B_0/μ** (eso sería solo “cuándo cruza cero la línea promedio, ignorando el ruido”). τ es una variable aleatoria en sí misma — tiene su propia distribución de probabilidad, porque dependiendo de cómo caigan los “sorteos” aleatorios del ruido, la trayectoria real podría cruzar antes o después del promedio.

2.8 Distribución Gaussiana Inversa — la solución cerrada

Existe un resultado matemático ya demostrado (no lo estamos inventando, es teoría clásica de procesos estocásticos) que dice: si $B(t)$ sigue un browniano con deriva, entonces **τ sigue exactamente una distribución Gaussiana Inversa** con parámetros:

$$\mu_{IG} = B_0 / |\mu| \quad \lambda_{IG} = B_0^2 / \sigma^2$$

Su función de densidad de probabilidad es:

$$f(\tau) = \left(\frac{\lambda_{IG}}{2\pi \cdot \tau^3} \right)^{1/2} \exp \left(- \frac{\lambda_{IG} \cdot (\tau - \mu_{IG})^2}{2 \cdot \mu_{IG}^2 \cdot \tau} \right)$$

(No necesitan memorizar ni derivar esta fórmula a mano — está aquí solo como referencia formal; en el código, `scipy.stats.invgauss` ya la implementa.)

No necesitan memorizar ni entender a profundidad esta fórmula. Lo importante es que `scipy.stats.invgauss` ya la implementa — ustedes solo necesitan calcular μ_{IG} y λ_{IG} a partir de sus tres datos (B_0 , μ , σ), y la librería les da:

- El día más probable de cruce: `mu_IG`
- Cualquier percentil del intervalo de confianza: `dist.ppf(percentil)`
- La probabilidad de haber quebrado antes de una fecha dada: `dist.cdf(fecha)`

Este último es el número que dispara la alerta del “Factor WOW”: **$P(\tau < T_{\text{finiquito}})$** .


3. Por qué esto es mejor que suavizado exponencial (y qué perdemos al usarlo)

	Suavizado exponencial	Browniano + Gaussiana Inversa
Da un intervalo de confianza nativo	No — hay que inventarlo con bandas ad-hoc	Sí — sale directo de la fórmula
Fundamento estadístico	Heurística de series de tiempo	Teoría de procesos estocásticos, con demostración formal
Complejidad de código	Similar	Similar (2 líneas con <code>scipy</code>)
Qué asume sobre el ruido	No lo modela explícitamente	Asume ruido gaussiano e independiente día a día

La ventaja real no es de código, es de **honestidad matemática frente al jurado**: pueden explicar

exactamente qué está calculando el sistema y por qué el intervalo de confianza significa algo real, no una banda decorativa.

4. El pipeline completo (las 3 capas, de datos crudos a predicción)



Punto de diseño importante: esta separación en capas no es solo prolijidad de código — significa que si el equipo decide cambiar los pesos del diccionario (por ejemplo, bajar el peso de “refacciones” de 0.8 a 0.6), **no se toca ni una línea del modelo matemático**. Son módulos independientes que se comunican solo a través de tres números.

5. Actualización día a día (el corazón de “por qué esto es un gemelo digital y no un reporte estático”)

Esta es la parte que hace que el sistema sea dinámico y no un cálculo de una sola vez. Cada vez que entra una transacción nueva:

5.1 Ventana móvil (rolling window)

En lugar de recalculer con TODO el historial desde el día 1 (lo cual diluiría cambios recientes de comportamiento), se usa una ventana de los últimos **N días** (sugerido: 7-10 días para el MVP) para recalculer μ y σ .

```
def recalibrar_diario(flujo_historico, ventana=7):  
    flujo_reciente = flujo_historico[-ventana:]  
    mu = np.mean(flujo_reciente)  
    sigma = np.std(flujo_reciente)  
    return mu, sigma
```

Por qué ventana móvil y no todo el historial: si en la semana 1 la empresa gastó fuerte en setup inicial (servidores, licencias por adelantado) y luego se estabiliza, un promedio de todo el historial seguiría “castigada” por esos gastos iniciales durante semanas. La ventana móvil hace que el modelo reaccione a la tendencia *reciente*, que es lo que realmente importa para predecir el futuro cercano.

5.2 Por qué el intervalo de confianza se hace más angosto con el tiempo

Esto es un efecto matemático importante que vale la pena que el equipo entienda, porque es

intuitivamente lo que esperaríamos: **entre más datos observados, menos incertidumbre.**

Con pocos días de datos (ej. 3-4 días), σ estimado tiene mucha varianza propia — es una estimación ruidosa de una estimación. Conforme se acumulan más días en la ventana, μ y σ se estabilizan, y el intervalo de confianza (`high90` - `low90`) se va achicando. Esto es honesto: **el sistema debe mostrarse menos seguro al principio (día 1-3) y más seguro conforme pasa el tiempo (día 7+)**. Si el frontend muestra el mismo ancho de intervalo desde el día 1, están mintiendo sobre la certeza del modelo.

5.3 Disparo de la alerta (el webhook del documento original)

Cada recalibración diaria evalúa:

```
prob_quiebra = dist.cdf(T_finiquito)

if prob_quiebra > UMBRAL_ALERTA: # ej. 0.35 (35%)
    disparar_webhook_intervencion()
```

El umbral (`UMBRAL_ALERTA`) es una decisión de producto, no matemática — tienen que decidir qué tan conservador quieren ser. Un umbral bajo (ej. 20%) genera alertas más tempranas pero con más falsos positivos; un umbral alto (ej. 50%) espera a estar casi seguro, pero deja menos margen de reacción.

6. Ejemplo numérico completo (con datos reales de la simulación)

Con 15 días de datos simulados:

Parámetro	Valor
<code>Bo</code>	\$5,000.00
μ (drift diario)	-\$266.52
σ (volatilidad diaria)	\$237.30
Día esperado de quiebra (<code>μ_{IG}</code>)	18.8 días
Intervalo 90% de confianza	[13.2, 25.7] días
Intervalo 50% de confianza	[16.0, 21.1] días
Fecha del finiquito	Día 18
P(quiebra antes del finiquito)	46.0%

Interpretación para el equipo: con 46% de probabilidad de quebrar antes de cobrar, este es un caso límite — justo el tipo de escenario donde el sistema debería disparar la alerta de intervención, porque el riesgo es demasiado alto para dejarlo al azar, pero no tan extremo como para ser obvio a simple vista (ahí está el valor del modelo: detecta riesgo que no es evidente con solo mirar el número del saldo).

7. Pseudocódigo de referencia (arquitectura completa)

```
import numpy as np
from scipy.stats import invgauss

def calcular_flujo_diario(purchases, deposits, merchants, weights):
    """CAPA 2: aplica el diccionario, produce serie numerica pura."""
    flujo = defaultdict(float)
```

```

for d in deposits:
    flujo[d["transaction_date"]] += d["amount"]
for p in purchases:
    cat = merchants[p["merchant_id"]]["category"]
    peso = weights.get(cat, 0.1)
    flujo[p["transaction_date"]] -= p["amount"] * peso
return flujo

def calcular_riesgo(B0, mu, sigma, T_objetivo):
    """CAPA 3: el modelo matematico puro. No sabe nada de merchants."""
    mu_ig = B0 / abs(mu)
    lambda_ig = (B0 ** 2) / (sigma ** 2)
    dist = invgauss(mu_ig / lambda_ig, scale=lambda_ig)
    return {
        "dia_esperado": mu_ig,
        "intervalo_90": (dist.ppf(0.05), dist.ppf(0.95)),
        "prob_quiebra_antes_de_T": dist.cdf(T_objetivo),
    }

def ciclo_diario(cuenta_id, ventana=7):
    """Se ejecuta una vez por dia (o por webhook de nueva transaccion)."""
    purchases = nessie_get(f"/accounts/{cuenta_id}/purchases")
    deposits = nessie_get(f"/accounts/{cuenta_id}/deposits")
    flujo = calcular_flujo_diario(purchases, deposits, merchants_cache, CATEGORY_WEIGHTS)

    serie = list(flujo.values())[-ventana:]
    mu, sigma = np.mean(serie), np.std(serie)
    B0 = nessie_get(f"/accounts/{cuenta_id}")[ "balance" ]

    riesgo = calcular_riesgo(B0, mu, sigma, T_objetivo=FECHA_FINIQUITO)

    if riesgo["prob_quiebra_antes_de_T"] > UMBRAL_ALERTA:
        emitir_webhook(riesgo)

    return riesgo

```

8. Limitaciones que el equipo debe poder explicar si el jurado pregunta

1. **El browniano asume ruido gaussiano independiente día a día.** Si la mayoría del gasto viene de 1-2 transacciones grandes y esporádicas (en vez de muchas transacciones pequeñas), un modelo de Poisson compuesto (proceso de Cramér-Lundberg, teoría de ruina actuarial) sería más fiel a la realidad. Se descartó por mayor complejidad de calibración en 36 horas, no por ser matemáticamente inferior.
2. **Con pocos días de datos, σ es una estimación ruidosa.** El sistema es honesto sobre esto mostrando intervalos de confianza más anchos al principio (sección 5.2) — no debe presentarse como si tuviera certeza desde el día 1.
3. **Nessie no da timestamps con hora, solo fecha.** La granularidad real del modelo es diaria, no de milisegundos — el lenguaje de “detección en tiempo real al milisegundo” es narrativa de producto, no literal.
4. **El diccionario de pesos es una decisión de negocio, no un resultado matemático.** Los valores de `CATEGORY_WEIGHTS` son supuestos que el equipo define; el modelo no los “aprende” de los datos en este MVP (una versión futura podría estimarlos con datos históricos reales, pero eso está fuera del alcance de 36 horas).

9. Glosario rápido

Término	Definición en una línea
Proceso estocástico	Variable aleatoria que cambia con el tiempo
Movimiento Browniano	Modelo de ruido puro acumulado, sin tendencia
Drift (μ)	La tendencia/inclinación promedio del proceso
Volatilidad (σ)	Qué tan erráticas son las fluctuaciones alrededor del drift
First-passage time	El momento en que un proceso aleatorio toca una barrera por primera vez
Gaussiana Inversa	La distribución de probabilidad exacta de ese momento, para un browniano con deriva
Ventana móvil	Recalcular usando solo los últimos N días, no todo el historial
CDF (<code>dist.cdf</code>)	Probabilidad acumulada de que el evento ya haya ocurrido antes de cierto punto
PPF (<code>dist.ppf</code>)	La operación inversa: dado un percentil, da el valor correspondiente (para sacar el intervalo de confianza)

10. Resumen ejecutivo en una frase

El sistema modela el saldo de caja como un proceso aleatorio con tendencia (browniano con deriva), calibra su tendencia y volatilidad con los últimos días de transacciones ya clasificadas por criticidad, y usa la fórmula exacta del tiempo de primer paso a cero (Gaussiana Inversa) para calcular no solo cuándo es más probable que la empresa se quede sin liquidez, sino con qué grado de certeza — recalibrando todos los días conforme llegan nuevos datos.